

Pronóstico de ventas para tiendas-departamento de Walmart

SALVADOR GARCIA

En modelos de ML con gran cantidad de datos es importante considerar la viabilidad del modelo, en términos de escalabilidad y calidad del modelo

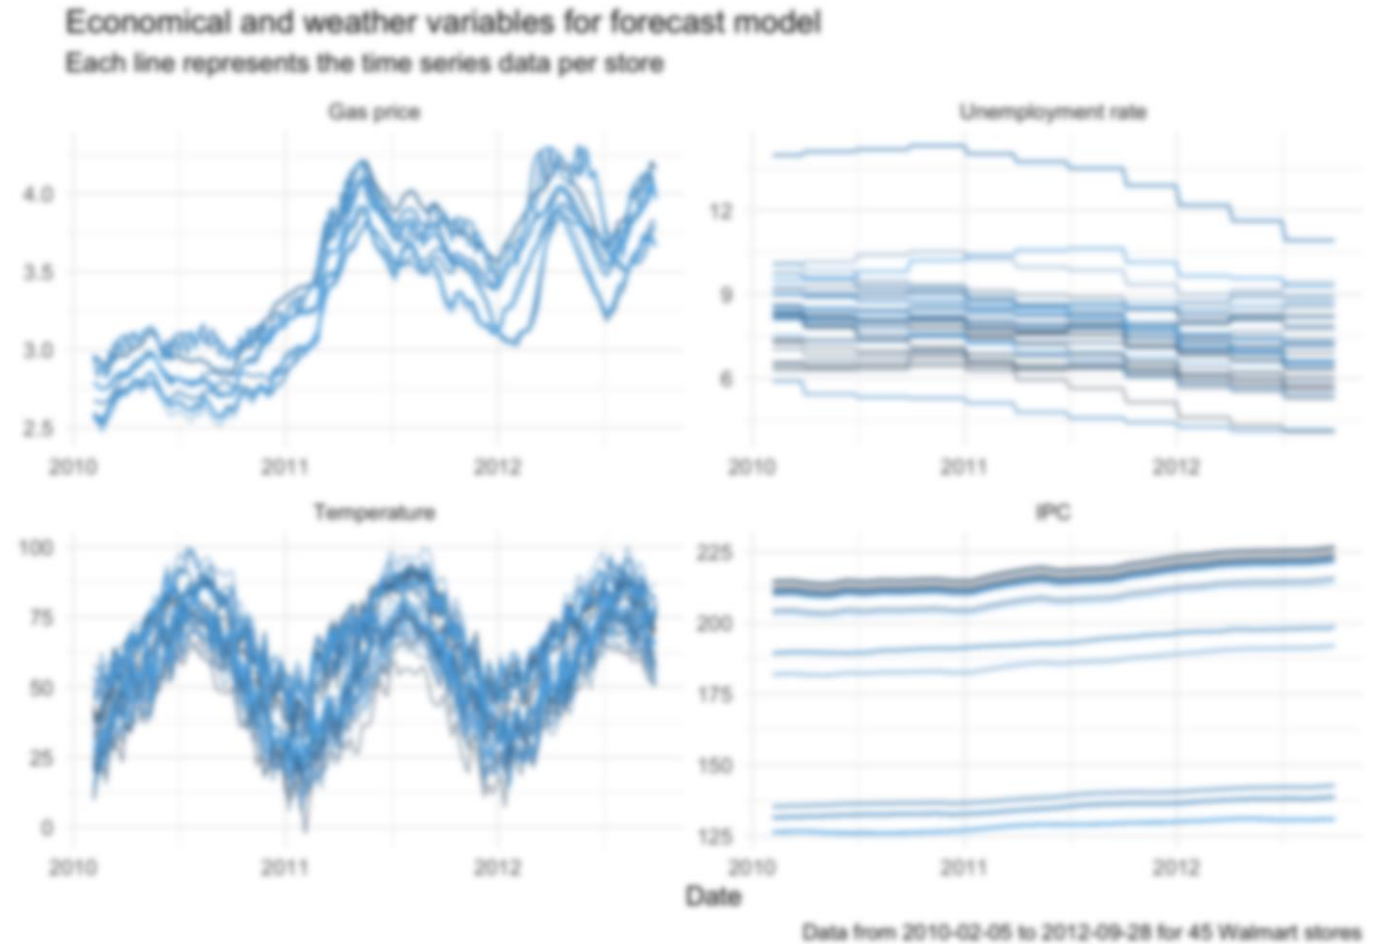
Un pronóstico a nivel tienda-departamento requiere 2500×98 pronósticos. Suponiendo un escenario donde el tiempo de respuesta es 1/10 de segundo, implica alrededor de 7 horas. **Solo de predicción.**

Consideraciones adicionales a tomar para la serie de tiempo:

- 25 MM de registros para el entrenamiento (suponiendo 2 años de historia)
- Tiempo adicional para evaluación de métricas de desempeño
- Tiempo adicional para evaluación de monitoreo continuo
- Tiempo adicional para reentrenamiento continuo
- Apertura de nuevas tiendas, cierre de tiendas
- Apertura de nuevos departamentos, cierre de departamentos

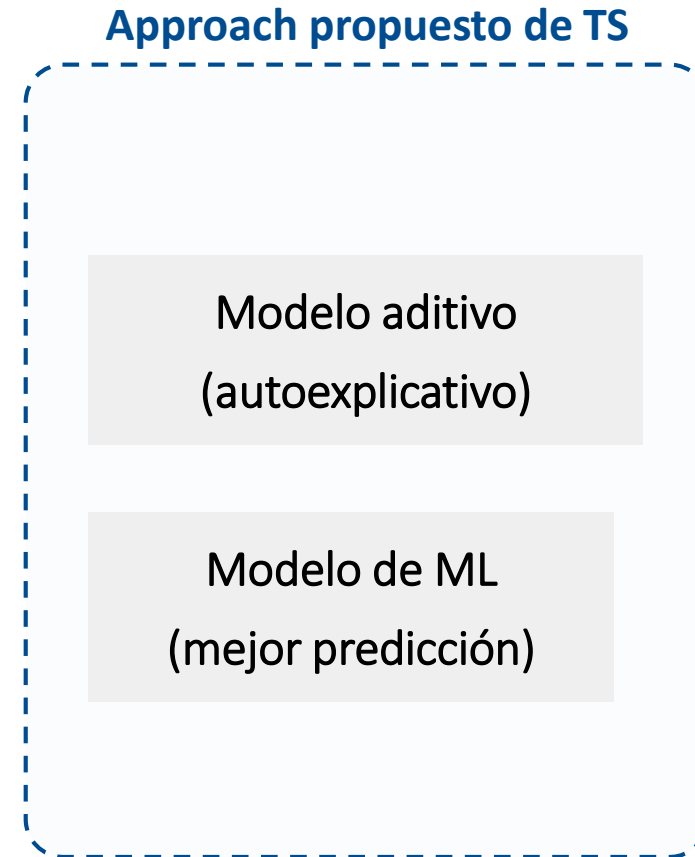
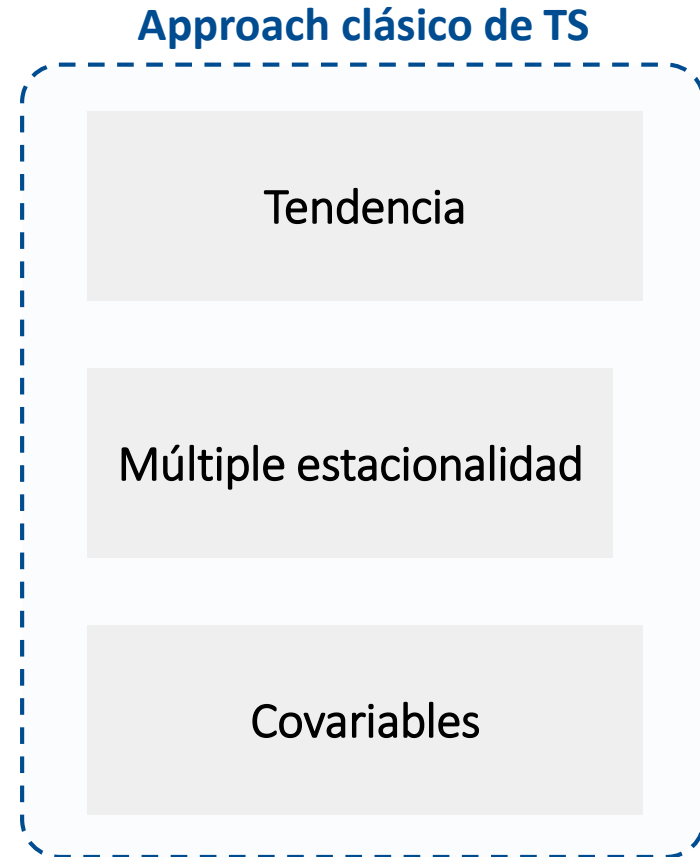
Estos puntos se convierten en puntos re restrictivos para evaluar la factibilidad de los modelos a evaluar.

Análisis Exploratorio de TS de Walmart



Los modelos clásicos de Time Series (TS) buscan ajustar una sola serie


Esto lo realizan descomponiéndola en distintos factores (aditivos o multiplicativos). Por otra parte un modelo aditivo o uno de ML, permitiría entrenar un solo modelo con interacciones por tienda o departamento.



En el approach propuesto, se busca emular la tendencia (splines o lags) y la estacionalidad (covariables).

Las ventas de Walmart en el muestreo de 45 sucursales exhiben un patrón estable, siendo el formato de tienda A el de mayor ventas

A grandes rasgos, las últimas semanas del año muestran un pico de ventas, el cual es bastante parecido entre los años mostrados en los datos. No se observan datos outliers en la TS.



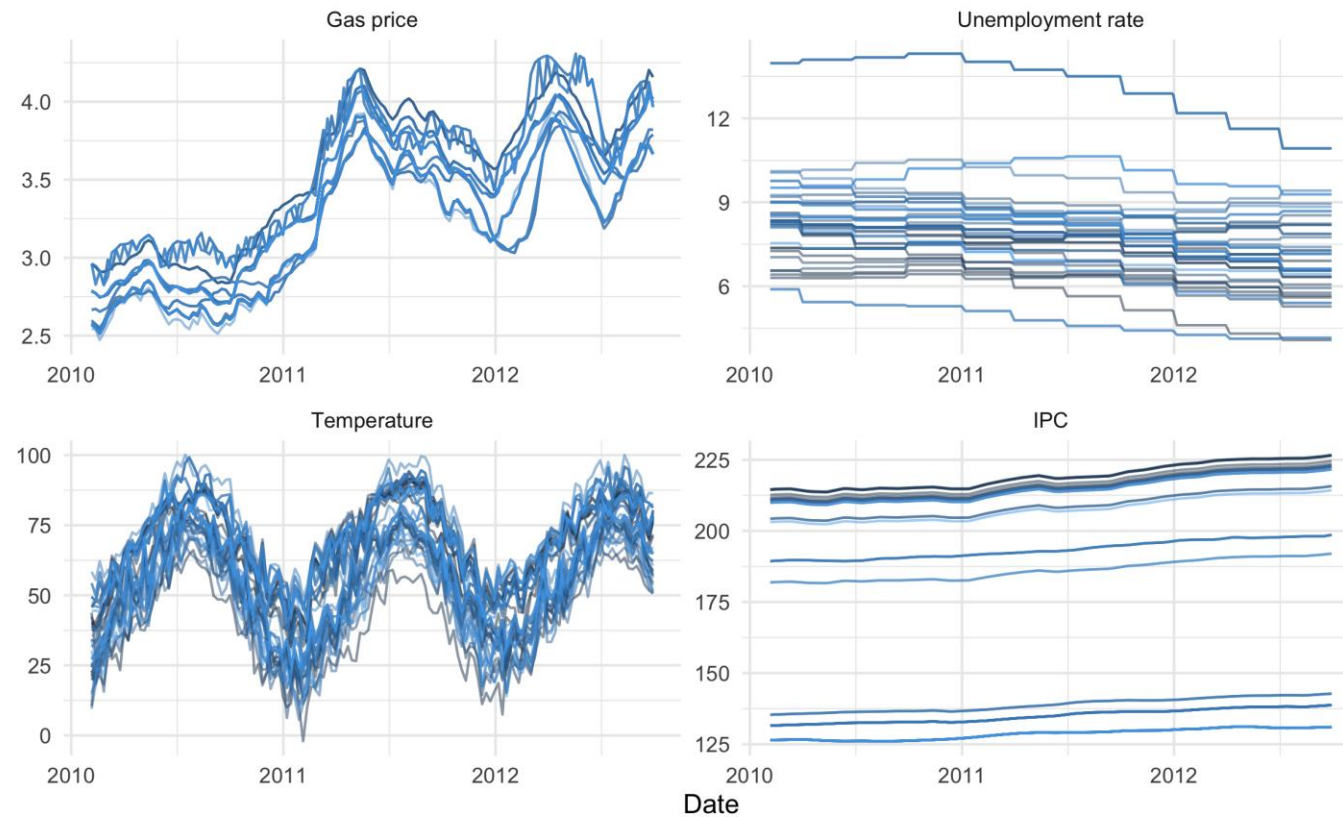
Data from 2010-02-05 to 2012-09-28 for 45 Walmart stores

Analizando las covariables económicas y de clima, se muestran comportamientos estables, en particular para la temperatura

Se debe tomar en cuenta la disponibilidad de datos al momento de la predicción. Es decir, no incluir en el modelo variables que no estén disponibles (si es factible, incluirlas con el lag adecuado).

Economical and weather variables for forecast model

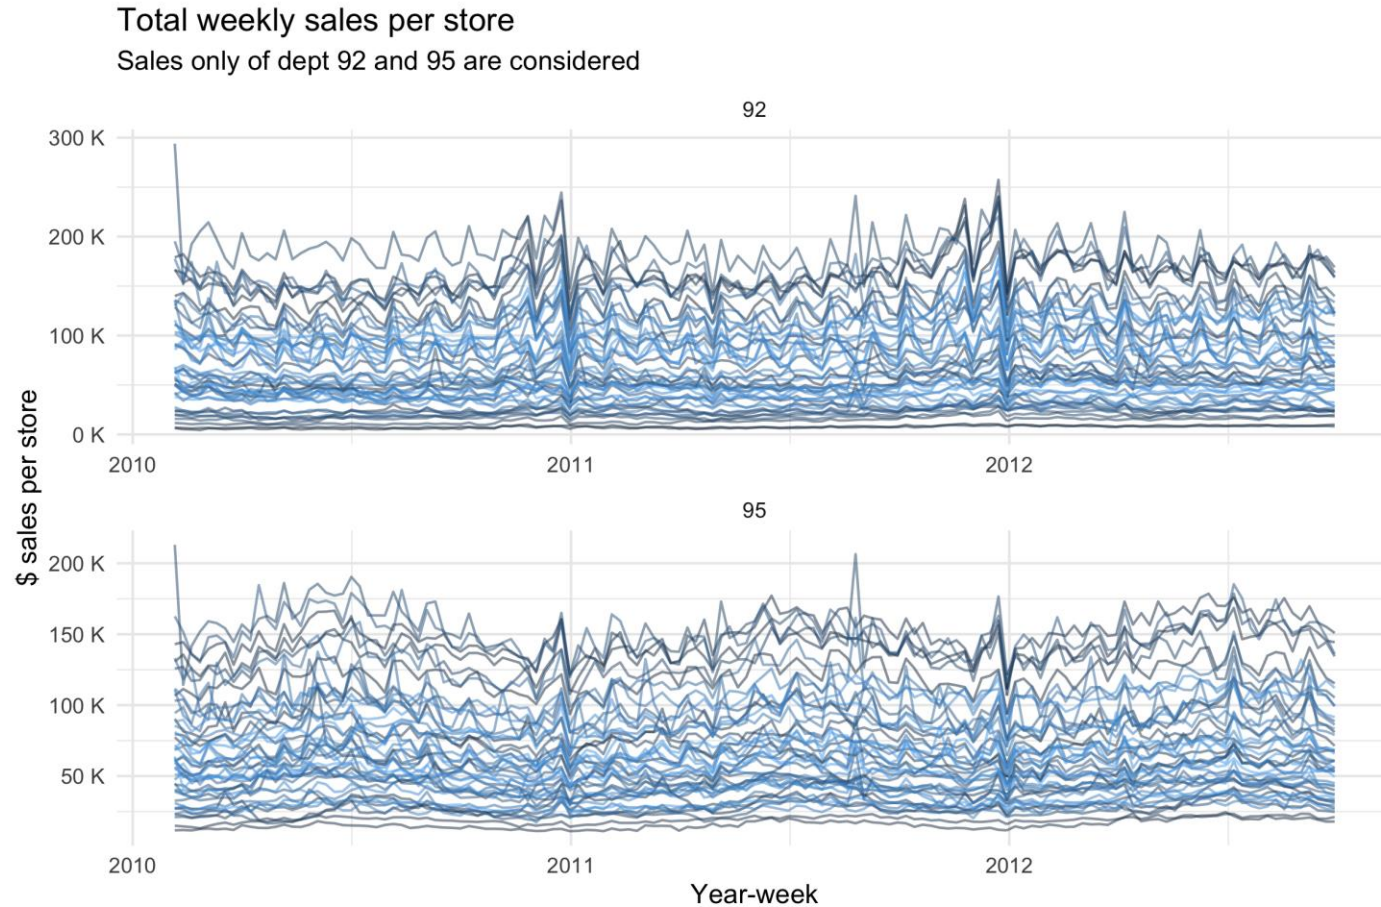
Each line represents the time series data per store



Data from 2010-02-05 to 2012-09-28 for 45 Walmart stores

Se analizó el comportamiento a nivel tienda de los dos departamentos con mayores ventas (92,95), esto con el fin de detectar posibles TS outliers

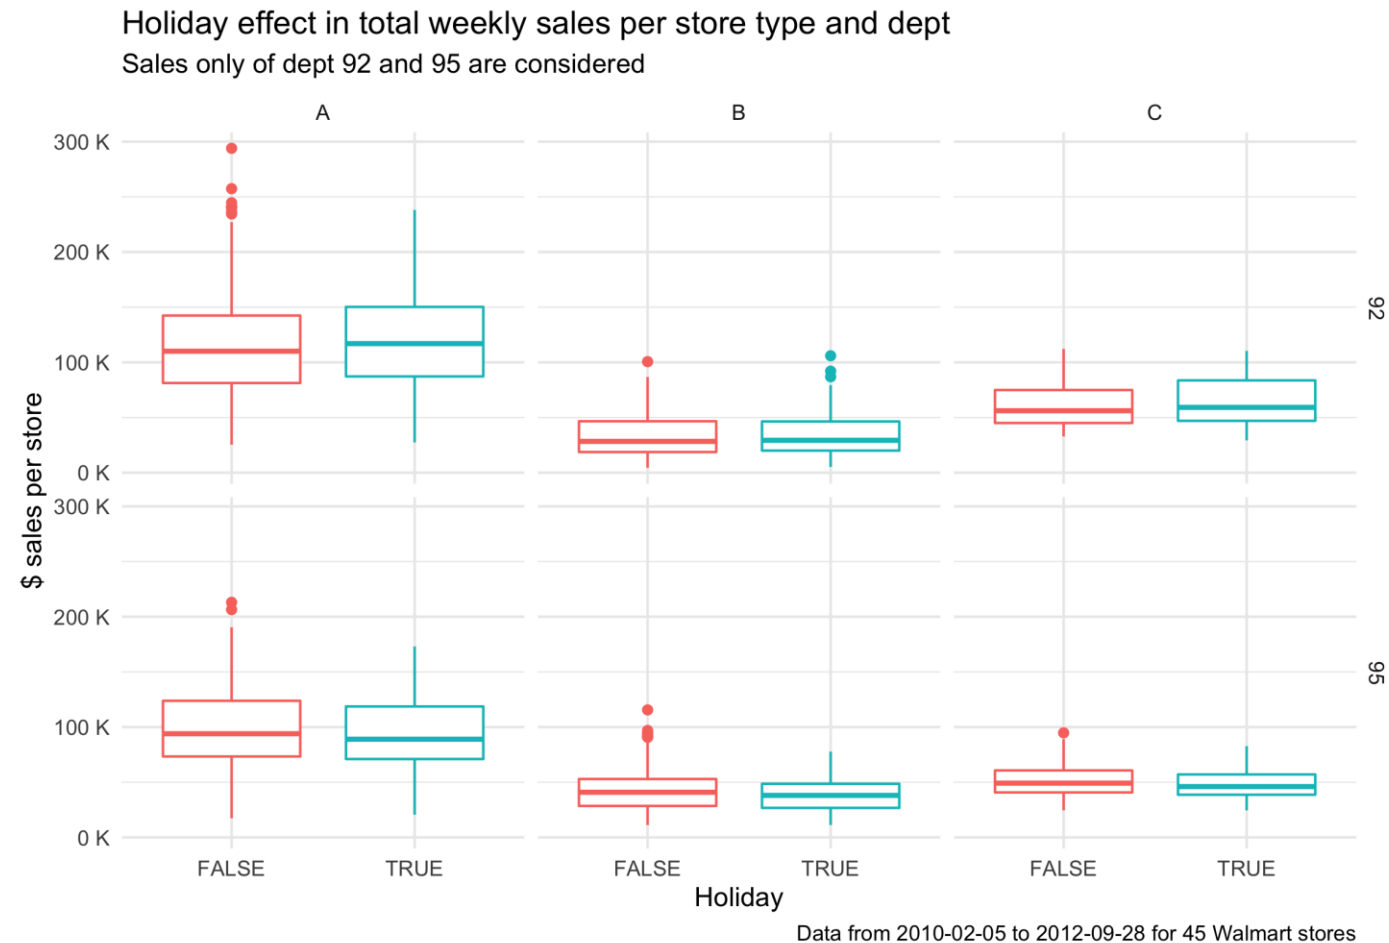
De nuevo, se encontró que las tiendas exhiben un comportamiento adecuado. No se considera necesario un análisis detallado a nivel tienda-departamento.



Data from 2010-02-05 to 2012-09-28 for 45 Walmart stores

Por último, no se encontró diferencia entre días festivos y no festivos

En la realidad es muy común que exista un efecto fuerte de los días festivos. En este ejemplo, al ser un toy set, no se detecta un efecto claro de día festivo.



El primer modelo propuesto para un benchmark es un modelo lineal aditivo con interacciones por tienda y departamento

Al ser un modelo lineal, el tiempo de entrenamiento es corto. La predicción, al ser un cálculo exacto, es computacionalmente factible (el lag mínimo considerado es 4 semanas, suponiendo que se pronosticarán 4 semanas en batch).

Descripción del modelo

Modelo lineal aditivo con regularización lasso

Variables consideradas:

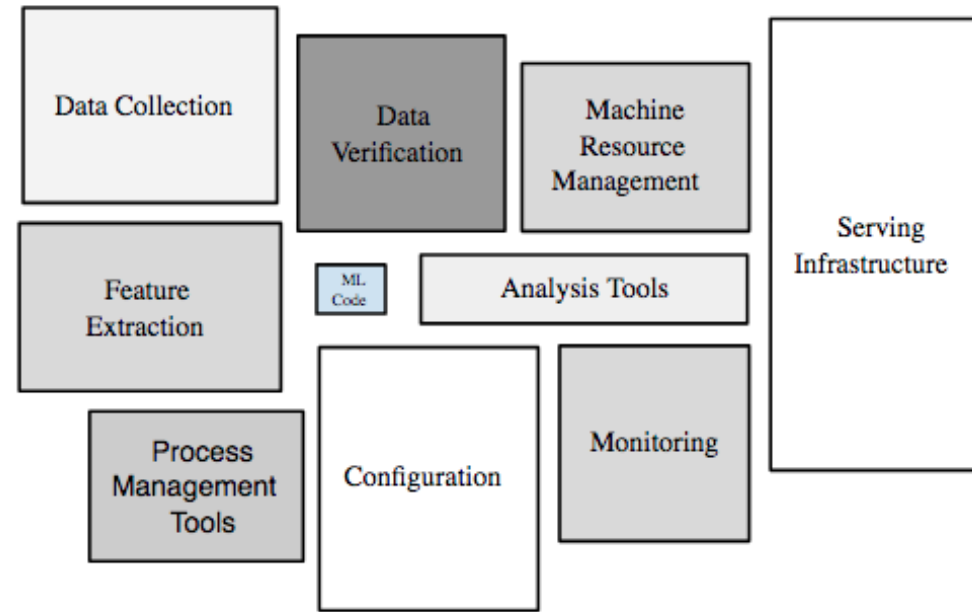
- Lag de ventas de un año
- Lag de ventas de 4,5,6,7 semanas
- Lag de temperatura de 4 semanas
- Lag de precio combustible de 4 semanas
- Lag de IPC de 4 semanas
- Lag de tasa de desempleo de 4 semanas
- Estacionalidad mensual
- Ajuste por tienda y departamento
- Interacción departamento para mes 12 y 6

Métricas de desempeño

RMSE: \$6,186

MAPE: 6.5%

Escalabilidad del modelo, roles e infraestructura



Data Scientist



Data Engineer



Visualization Expert



DevOps Engineer



Data Architect



Software development

Gobierno y versionamiento de modelos de ML

Automatización ETL

DA



Acceso y recolección de bases de datos

DE



Verificación de inputs a través del tiempo

DS

Retrain triggers



Optimización de vistas y automatización de feature engineering

DE

Gobierno de modelos

DA



Experimentación, creación y versionamiento de modelos

DS



Repositorio de modelos y métricas

DS

Retrain triggers



Base de datos de tiempos de consumo de recursos

DS

DE

Selección de modelo

DA



Selección automática del mejor modelo (basado en reglas)

DS



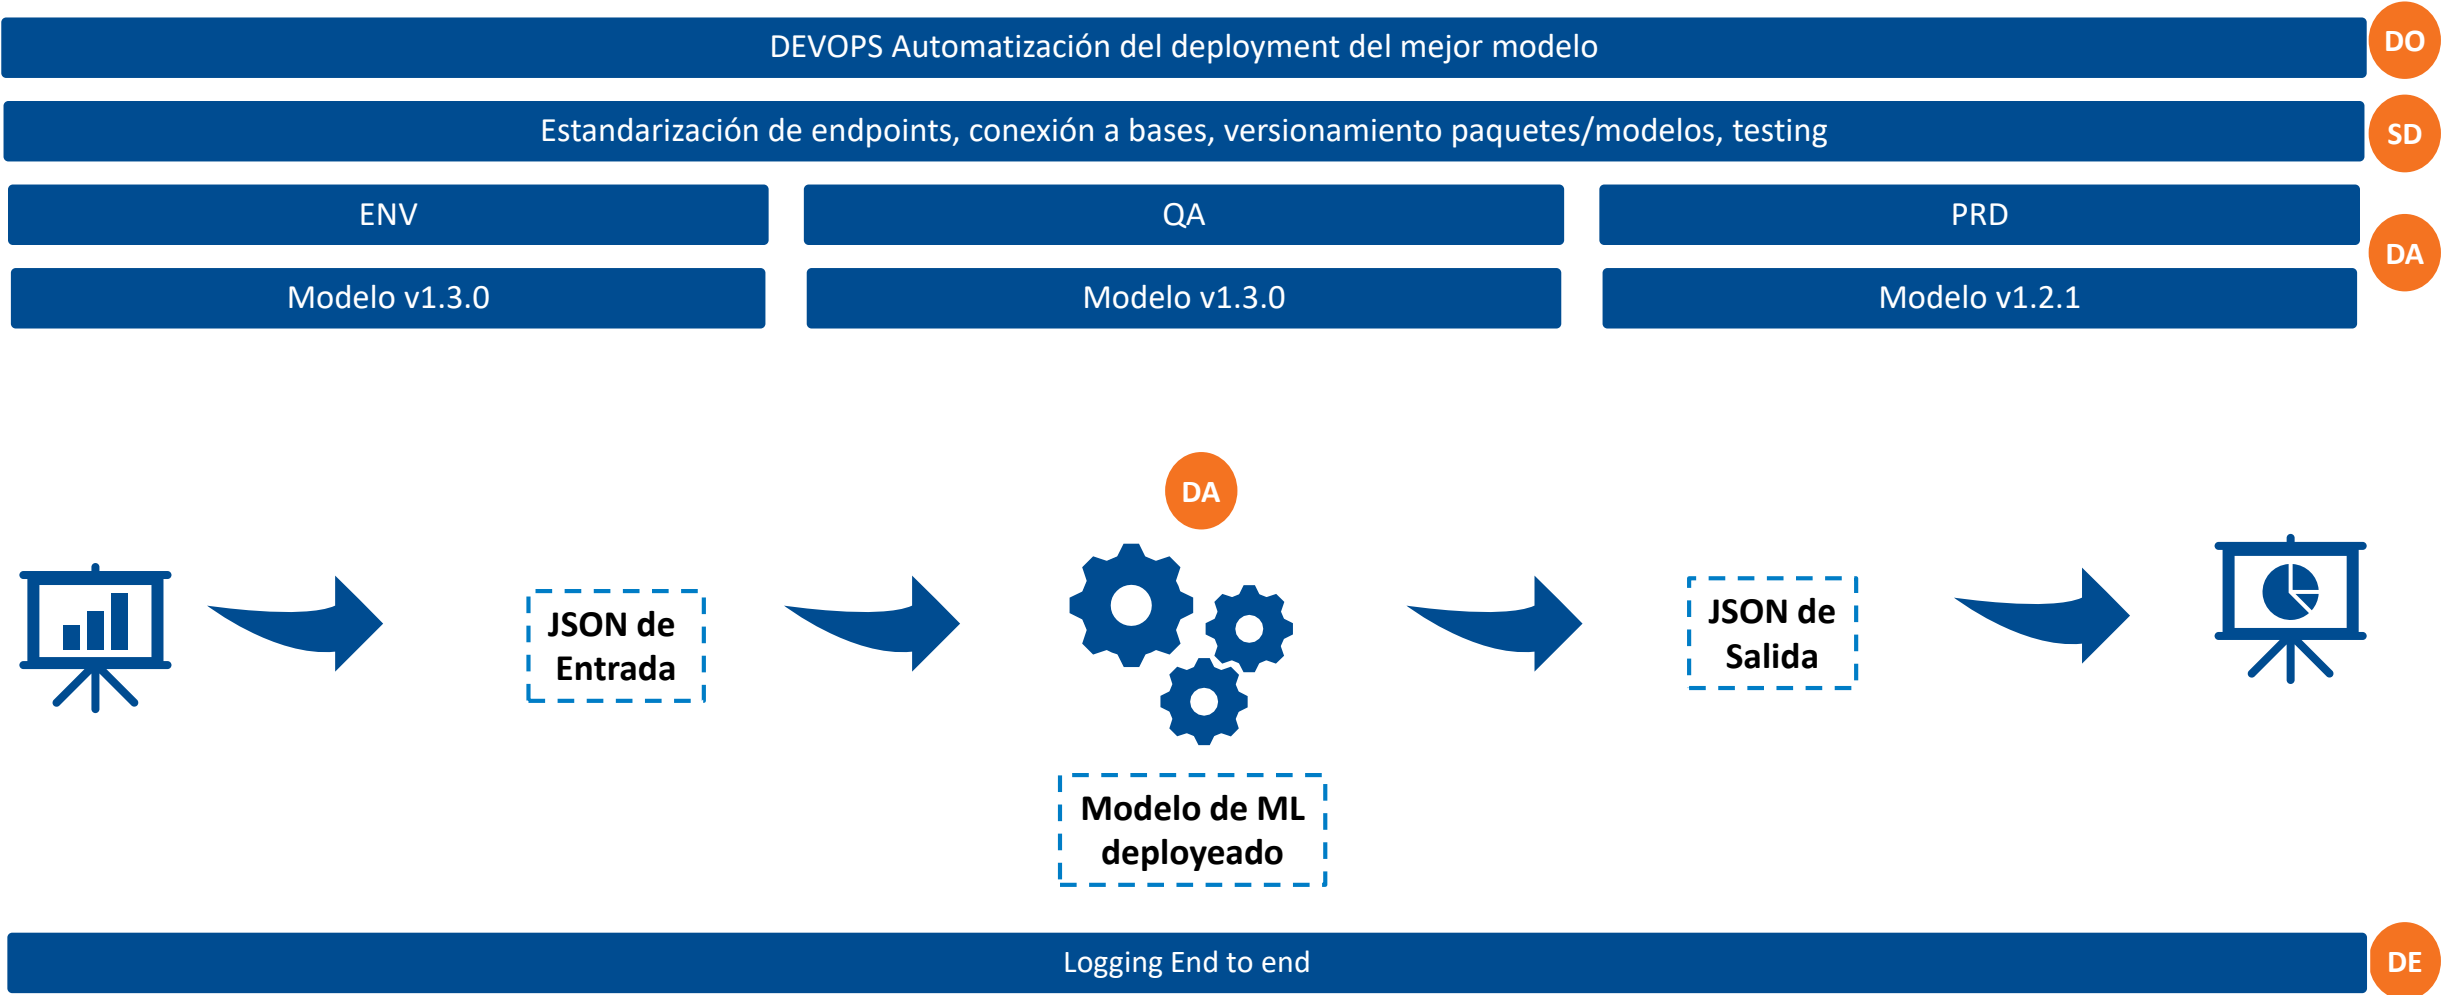
Automatización del deployment del mejor modelo

SD

DO

Automatización de deployments y E2E log saving

La automatización del flujo permite realizar un deployment continuo y un buen gobierno de modelos.



Ejecución del modelo y monitoreo continuo

Un monitoreo continuo permite ver los puntos débiles del modelo y priorizar por tiendas con mayor venta. Con esto, mejorar el modelo progresivamente.

Pool de métricas disponibles

SD

Monitoreo de performance
del modelo (training,
scoring, validation)

SD

DS

VE



Monitoreo de consumo
de recursos
computacionales
(costo)

SD

DS

VE



Monitoreo de uso

SD


DS

VE



Para el monitoreo de performance se pueden considerar distintas métricas como MAPE ajustado, MASE, RMSE, etc.

Propuestas de Feature Engineering



Mejoras y feature engineering adicionales al modelo

Se propone hacer un roadmap basado en microservicios generando variables adicionales que no solo serían de utilidad para el modelo de forecast, si no a demás áreas y modelos analíticos.

- **Modelo día festivo** – Medir con mayor precisión el efecto de día festivo (distinto efecto 1ro mayo a 25 de diciembre)
- **Modelo de temporada** – Medir con mayor precisión el efecto de temporadas (verano, navidad, semana santa) por departamento
- **Modelo de promociones** – Medir con mayor precisión el efecto de las promociones más significativas para los departamentos
- **Monitorear eventos** – Eventos deportivos/culturales/políticos pueden tener un efecto por tienda/departamento
- **Variables climatológicas** – Lluvia, temperatura, nieve, etc
- **Índices económicos por actividad económica** – Para complementar el efecto de tendencia
- **Metros cuadrados por departamento-tienda** – Tiendas con muchos metros cuadrados para un departamento podría indicar ventas altas de ese departamento
- **Indicador de competencia en la región** – Apertura de tiendas de competencia, etc

Estas variables pueden mejorar o no el modelo, pero se puede experimentar para incluirlas en el modelo.